Introducción

El presente informe tiene como objetivo realizar un análisis exploratorio técnico (EDA) del corpus AG News, un conjunto de datos compuesto por noticias en inglés clasificadas en cuatro categorías: World, Sports, Business y Sci_Tech.

El análisis se realizó sobre el conjunto de entrenamiento (ag_news_train.csv), que contiene 8.000 noticias, luego de aplicar el pipeline de preprocesamiento desarrollado durante el Módulo 2.

El propósito es evaluar la calidad del corpus después de la limpieza, analizar las características del vocabulario y de las secuencias de texto.

Pasos de preprocesamiento aplicados

Se desarrolló y aplicó una función de preprocesamiento sobre la columna text de cada noticia del conjunto de entrenamiento.

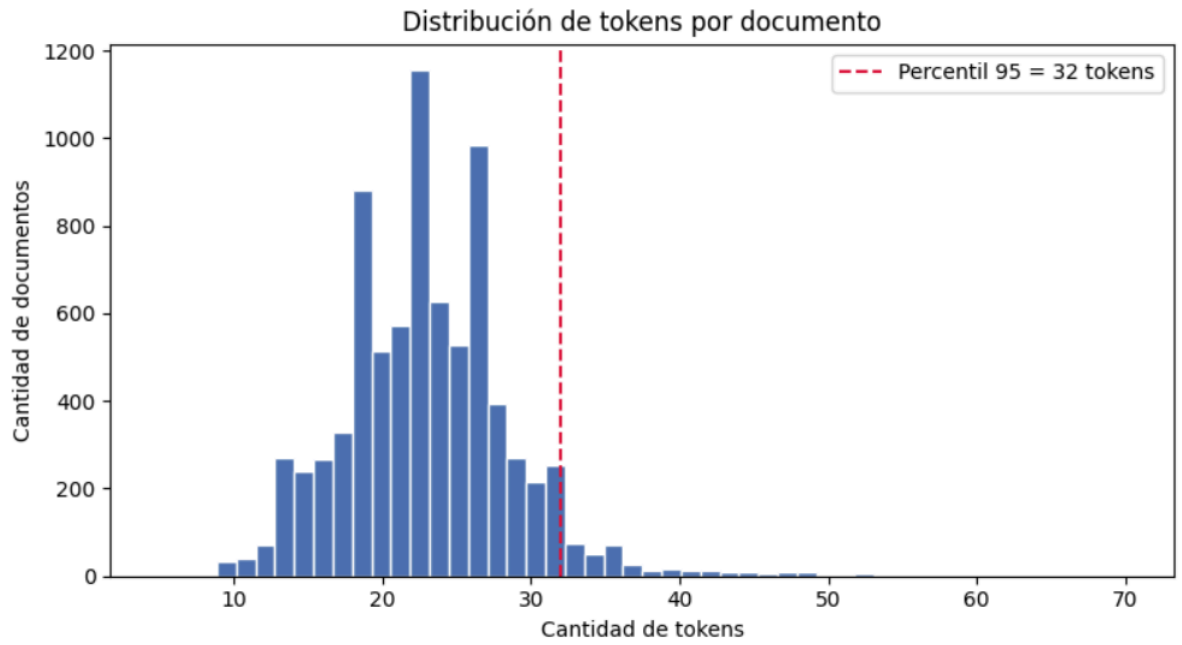
Durante este proceso se realizaron las siguientes operaciones, respetando el orden de ejecución:

1. **Decodificación de entidades HTML:** conversión de códigos como < y > a sus caracteres correspondientes.
2. **Eliminación de etiquetas HTML y URLs:** utilización de expresiones regulares para remover elementos que no aportan información al contenido de las noticias.
3. **Eliminación de dominios web:** remoción de dominios sin protocolo, como washingtonpost.com.
4. **Eliminación de firmas de agencias de noticias:** se removieron referencias a Reuters, AP, AFP, Canadian Press y Quote, Profile, Research, ya que aparecían repetidamente al comienzo de muchas noticias y afectaban los resultados de frecuencia de los N-gramas.
5. **Eliminación de entidades HTML residuales:** remoción de fragmentos que no habían sido decodificados correctamente, como quot;, amp; y códigos numéricos como #39;.
6. **Normalización a minúsculas:** conversión de todo el texto para evitar que una misma palabra se considere diferente por el uso de mayúsculas.
7. **Eliminación de números, puntuación y símbolos:** conservación únicamente de caracteres alfabéticos.
8. **Lematización con SpaCy:** utilización del modelo en_core_web_sm para transformar las palabras a su forma base. Por ejemplo, lawsuits pasa a lawsuit.
9. **Eliminación de stop-words y tokens de una sola letra:** remoción de palabras frecuentes sin aporte significativo para el análisis y de tokens demasiado cortos.

Como resultado, cada noticia queda representada por una secuencia de lemas en minúsculas, sin elementos de formato ni ruido textual.

Distribución de la longitud de tokens por documento

Para analizar la extensión de las noticias, se calculó la cantidad de tokens de cada documento luego de aplicar el preprocesamiento.



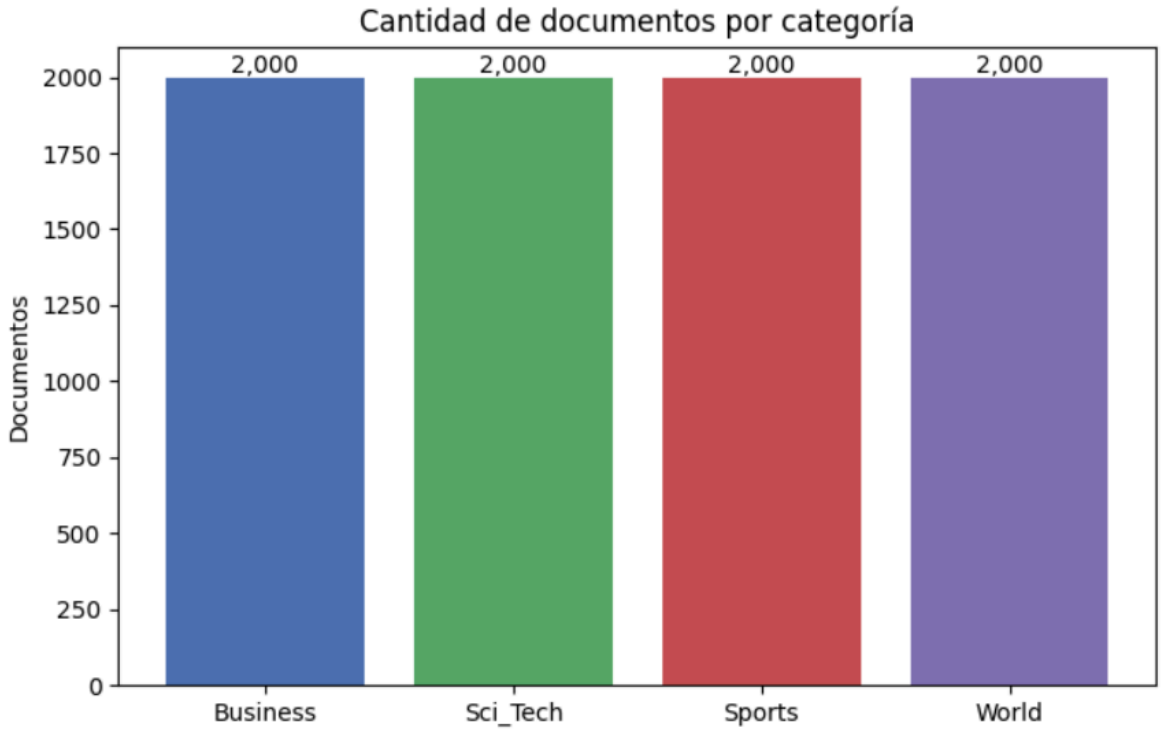
El histograma muestra una distribución concentrada: la mayoría de las noticias contiene entre 15 y 32 tokens. La mediana es de 23 tokens y se observa una cola derecha relativamente corta, con un máximo de 70 tokens.

El percentil 95 es de 32 tokens, lo que significa que el 95 % de las noticias tiene 32 tokens o menos.

A partir de este resultado, se establece un valor de max_len = 32 para los próximos módulos. Esta decisión permite conservar la mayor parte de la información del corpus y limitar el truncamiento aproximadamente al 5 % de los documentos. Además, evita utilizar secuencias excesivamente largas y reduce la cantidad de padding necesario durante el entrenamiento.

Distribución de clases

Se analizó la cantidad de noticias pertenecientes a cada una de las cuatro categorías del conjunto de entrenamiento.



Los resultados muestran que las cuatro categorías presentan exactamente la misma cantidad de documentos:

- Business: 2.000 noticias.
- Sci_Tech: 2.000 noticias.
- Sports: 2.000 noticias.
- World: 2.000 noticias.

Por lo tanto, el conjunto de entrenamiento se encuentra perfectamente balanceado.

Esta distribución es favorable para el modelado, ya que no existe una categoría predominante que pueda generar un sesgo en el aprendizaje.

Análisis de los bi-gramas y tri-gramas más frecuentes

Para identificar las combinaciones de palabras más frecuentes del corpus, se utilizó CountVectorizer de la biblioteca scikit-learn sobre los textos preprocesados.

Top 20 bi-gramas

2-grama	frecuencia
new york	419
oil price	197
united states	167
prime minister	139

official say	115
say thursday	102
say monday	101
say tuesday	98
red sox	98
los angeles	96
san francisco	96
president bush	93
say wednesday	90
say friday	88
year old	88
mobile phone	72
wall street	71
microsoft corp	70
world cup	69
kill people	67

Los resultados muestran que las combinaciones más frecuentes están relacionadas principalmente con:

- **Lugares geográficos:** aparecen expresiones como new york, los angeles y san francisco.
- **Política y figuras públicas:** se destacan combinaciones como prime minister y president bush.
- **Economía:** aparecen términos como oil price y wall street.
- **Deportes y tecnología:** se identifican expresiones como red sox, world cup y mobile phone.
- **Expresiones periodísticas:** también se encuentran combinaciones como say monday, say thursday y official say.

Estos resultados permiten observar que el vocabulario del corpus está relacionado con los principales temas tratados en las noticias y que existen algunas expresiones propias del lenguaje periodístico.

Top 20 tri-gramas

3-grama	frecuencia
new york stock	37

boston red sox	37
high oil price	27
prime minister ariel	26
minister ariel sharon	25
state colin powell	22
secretary state colin	22
president george bush	21
president vladimir putin	21
new york yankees	21
security exchange commission	20
crude oil price	20
international space station	18
minister tony blair	17
prime minister tony	17
los angeles dodger	16
st louis cardinal	16
oil price rise	15
mart stores inc	15
initial public offering	15

En el caso de los tri-gramas, se observan combinaciones más específicas que permiten identificar entidades y conceptos completos.

Entre los resultados se destacan:

- new york stock y boston red sox, relacionados con economía y deportes.
- prime minister ariel sharon, secretary state colin powell y president george bush, vinculados con figuras políticas.

- high oil price, crude oil price y oil price rise, relacionados con temas económicos.
- international space station, asociado con ciencia y tecnología.

También aparecen expresiones periodísticas y referencias a personalidades políticas de una época determinada, lo que permite reconocer características propias del contenido del dataset.

En general, los N-gramas obtenidos muestran que, después de la limpieza, predominan combinaciones con significado y relación temática, sin que los resultados estén dominados por URLs, etiquetas HTML o firmas de agencias de noticias.

Análisis de las 50 palabras más frecuentes

Se calculó la frecuencia de las 50 palabras más utilizadas en el corpus y se verificó cuáles de ellas estaban identificadas como stop-words por SpaCy.

Palabra	Frecuencia	es_stopword
the	13698	True
to	7975	True
of	6578	True
in	6363	True
and	4637	True
on	3773	True
for	3410	True
that	1929	True
with	1771	True
as	1720	True
at	1669	True
its	1501	True
it	1437	True
new	1420	False
is	1395	True
by	1357	True
said	1352	False
has	1263	True

from	1221	True
an	1194	True
will	1001	True
after	947	True
his	940	True
was	924	True
us	890	True
over	800	True
be	777	True
have	776	True
their	733	True
up	713	True
two	675	True
first	672	True
are	646	True
year	644	False
he	599	True
but	598	True
world	591	False
more	578	True
one	569	True
this	543	True
out	539	True
oil	519	False
monday	517	False
wednesday	505	False
thursday	502	False
not	498	True
tuesday	494	False

company	493	False
friday	478	False
last	468	True

Para realizar este análisis, las frecuencias se calcularon sobre el texto limpio antes de eliminar las stop-words. De esta manera, fue posible identificar su presencia e importancia dentro del vocabulario original.

Los resultados muestran que 39 de las 50 palabras más frecuentes son stop-words, entre ellas the, to, of, in y and. Estas palabras tienen una frecuencia elevada, pero generalmente aportan poca información para diferenciar las categorías de las noticias.

Las 11 palabras restantes corresponden a términos de contenido o expresiones frecuentes del lenguaje periodístico, como new, said, year, world, oil y company. También aparecen los días de la semana, como monday, tuesday y friday.

Aunque estas palabras no son stop-words, algunas presentan un valor discriminativo limitado, por lo que podrían evaluarse en futuras etapas del procesamiento.

Conclusión

Uno de los aspectos que más trabajo me llevó durante este ejercicio fue la limpieza del texto. Tuve que revisar y modificar el proceso varias veces, ya que a medida que analizaba los resultados aparecían nuevos elementos que necesitaban ser eliminados, como entidades HTML, dominios y firmas de agencias de noticias. Esto me permitió entender que la limpieza no es un proceso que se realiza una sola vez, sino que requiere revisar los resultados y realizar ajustes cuando es necesario. También me resultó muy útil tener definidos los pasos del preprocesamiento, ya que me permitió organizar mejor el trabajo y detectar dónde realizar las modificaciones.

Otro aspecto importante fue el tratamiento de las stop-words. Al analizar las 50 palabras más frecuentes, encontré que 39 eran stop-words, por lo que su eliminación ayudó a reducir palabras que aportaban poca información. Además, los N-gramas permitieron comprobar que, después de la limpieza, predominaban combinaciones relacionadas con el contenido de las noticias y no elementos de formato.

Por otro lado, el análisis de longitud permitió establecer 32 tokens como valor de max_len, mientras que la distribución de clases mostró que las cuatro categorías están perfectamente balanceadas.

En conclusión, considero que el corpus quedó preparado para avanzar con las siguientes etapas de modelado, ya que se redujo el ruido textual, se normalizaron los documentos y se identificaron parámetros importantes para el entrenamiento. El conjunto de test se mantiene reservado para la evaluación final.